


AI Vision Sensor 공격에 따른 교란 방식 보고서

< AI Vision Sensor 교란 방식 >

- 컴퓨터 비전 분야에서 적대적 공격(Adversarial Attack), 그중에서도 물리적 환경에서 작동하는 적대적 패치(Adversarial Patch) 또는 적대적 위장(Adversarial Camouflage) 기술에 해당.
- 인간의 눈에는 단순한 체크무늬나 난해한 기하학 타일처럼 보이지만, AI 모델(YOLO, CNN 기반 객체 인식기 등)의 내부 연산 구조를 정밀하게 타격하도록 계산된 패턴임. 작동 원리와 주요 교란 방식을 아래와 같이 정리하였음.

□ 핵심 작동 원리

- **AI Vision Sensor**는 이미지의 픽셀 간 대비, 경계선(Edge), 그리고 질감(Texture) 정보를 단계별로 조합하여 객체를 인식, 흑백 기하학 패턴은 이 메커니즘의 취약점을 노림.
 - **특징값 왜곡(Feature Distortion)**: AI가 사물의 고유 형태(예: 차량의 윤곽, 사람의 실루엣)를 파악하기 전에, 강력한 흑백 대비의 기하학적 특징(Feature)을 인공적으로 주입하여 신경망 내부의 활성화 지도(Activation Map)를 교란
 - **손실 함수 최적화(Loss Function Optimization)**: 이 패턴들은 무작위로 그려진 것이 아님. 특정 AI 모델의 인식 신뢰도(Confidence Score)를 가장 효과적으로 떨어뜨리거나, 아예 다른 물체로 오인하도록 수학적으로 역계산(Gradient Descent)하여 생성된 최적의 기하학적 형태 임.



적대적 패치(Adversarial Patch)를
활용한 객체 탐지
무력화 예시. 출처: ar5iv - arxiv

□ 주요 교란 방식(공격 메커니즘)

① 회피 공격(Vanishing / Non-Detection)

- 방식: 차량 지붕, 드론 상부 또는 작전 요원의 의복에 특정 흑백 패턴을 인쇄하는 방식
- 효과: AI 비전 센서가 해당 영역을 배경(Background)의 일부로 인식하거나, 객체가 존재한다는 신뢰도(Confidence) 자체를 그리드 내부에서 상쇄시켜 버림. 결과적으로 Bounding Box(객체 지정 사각형)가 생성되지 않아 AI 눈에 “투명인간”처럼 변함

② 오분류 공격(Misclassification)

- 방식: 표적의 표면에 정밀하게 계산된 흑백 기하학 스티커나 도장(Painting)을 적용
- 효과: AI 군사 자산이나 자율주행 센서가 군용 트럭을 “민간 승용차”로 혹은 탱크를 “바위”나 “식물”로 잘못 분류하게 만듦. 데이터셋 내부의 오차 경계를 교묘하게 찌르는 기하학적 배열이 이 역할을 함

③ 주의분산공격(False Positive / Anchor Fooling)

- 방식: 물체가 없는 허공이나 엉뚱한 장소에 특정 기하학적 문양의 표지판이나 패치를 배치
- 효과: AI의 앵커 박스(Anchor Box) 알고리즘을 강제로 자극하여, 아무것도 없는 곳에 “민간인”이나 “위협자산”이 있다고 착각하게 만듦. 시스템에 수많은 가짜 경고(False Alarm)를 발생시켜 비전 연산 자원을 고갈시키거나 지휘 통제 시스템에 혼란을 줌

□ 현대 전장 및 보안에서의 실전적 의미

적은 비용으로 고가의 고성능 AI 감시 자산(정찰 드론, AI 기반 CCTC, 국경 감시 시스템)을 무력화할 수 있어 비대칭 전략으로 연구되고 있음

< 특히 흑백 패턴이 선호되는 이유 >

- 조도 변화에 대한 강인함: 컬러 패턴은 일출, 일몰, 악천후 등 광원 변화에 따라 AI가 인식하는 RGB 값이 크게 달라져 교란 성능이 떨어짐. 반면 흑백 기하학 패턴은 명암 대비(Contrast)에 의존하므로 저해상도 카메라나 열화상 센서(적외선 채널의 방사를 차이 설계시)를 상대로도 일정 수준 이상의 교란 성능을 유지 함